

Classification Robuste et Analyse de Decision en Environnement Critique

Prediction de pannes APS - Scania Trucks

Methodologie : EDA, Elastic Net, Random Forest, XGBoost,
Calibration, SHAP

Dataset : 60 000 train / 16 000 test | 1000 pos / 59000 neg

Desequilibre ~ 59:1 (1.67 % positifs)

Cout : FP=10 EUR | FN=500 EUR

Date : 01/06/2026

Page de garde

Titre : Classification Robuste et Analyse de Décision en Environnement Critique

Sous-titre : Prédiction de pannes du système de pression d'air (APS) — Scania Trucks

Méthodologie : Feature engineering exploratoire, Elastic Net, Random Forest (proximité OOB), XGBoost cost-sensitive (Optuna), calibration des probabilités, interprétabilité SHAP

Dataset : UCI APS Failure and Operational Data at Scania Trucks — 60 000 observations d'entraînement, 170 capteurs, déséquilibre $\approx 59:1$ (1.67 % de positifs)

Encadrement : [Nom du professeur / UE]

Auteur : [Nom Prénom]

Date : Juin 2026

Table des matières

Générée automatiquement à l'export PDF (Pandoc/LaTeX).

Introduction

Contexte métier

Les camions Scania embarquent un vaste réseau de capteurs supervisant notamment le système de pression d'air (APS), qui alimente le freinage et les changements de vitesse. Une défaillance APS non détectée peut provoquer une immobilisation coûteuse ou un risque sécuritaire. Le jeu de données APS Failure at Scania Trucks (Scania CV AB, challenge industriel IDA 2016) propose de prédire, à partir de lectures de capteurs anonymisées, si un enregistrement correspond à une panne liée à l'APS (classe positive) ou à une autre défaillance (classe négative).

Problématique

Trois difficultés structurent ce problème :

1. ****Déséquilibre extrême**** — environ 59 000 négatifs pour 1 000 positifs sur l'ensemble d'entraînement (ratio $\approx 59:1$, soit 1.67 % de positifs).
2. ****Coût asymétrique de classification**** (métrique officielle du challenge) :
 - Faux positif (FP) : 10 € — contrôle atelier inutile ;
 - Faux négatif (FN) : 500 € — panne non anticipée.
3. ****Données bruitées et incomplètes**** — valeurs `na`, capteurs redondants (multicolinéarité), distributions non gaussiennes.

Un modèle naïf prédisant toujours « pas de panne APS » atteindrait une accuracy $\approx 98,3$ % tout en étant inacceptable opérationnellement (FN massifs).

Objectifs

Objectif | Approche retenue

----- | -----

Robustesse au déséquilibre | `class\_weight`, SMOTE dans `imblearn.Pipeline`, `scale\_pos\_weight` / focal loss (XGBoost)

Décision fiable | Calibration (Platt / isotonic), analyse ECE, seuil optimisé sur coût métier

Interprétabilité | SHAP `TreeExplainer` sur le meilleur modèle arborescent

Reproductibilité | `seed=42`, `StratifiedKFold(5)`, code versionné (`src/`, notebooks 01–04)

Structure du rapport

- ****Chapitre 1**** — Analyse exploratoire et préparation (notebook 01).
- ****Chapitre 2**** — Développement de trois modèles (notebook 02).
- ****Chapitre 3**** — Évaluation sur le test set et calibration (notebook 03).
- ****Chapitre 4**** — Interprétabilité SHAP (notebook 04).
- ****Conclusion**** — Synthèse, limites, perspectives et recommandations de déploiement.

****Mise à jour automatique des chiffres : **** exécuter ``python scripts/extract_report_metrics.py --fill``

reports/rapport_aps_scania.md` après les notebooks pour remplir les balises `{{...}}` à partir de
`data/processed/eda\_results.joblib` et `reports/tables/\*.csv`.

Chapitre 1 — Analyse exploratoire et préparation (Étape 1)

1.1 Statistiques descriptives

Dimensions et cible

Indicateur | Valeur

----- | -----

Train | (60000, 171) (attendu : 60 000 × 171)

Test | (16000, 171) (attendu : 16 000 × 171)

Features | 170 capteurs + `class`

Positifs (panne APS) | 1000

Négatifs | 59000

Proportion positifs | 1.67 %

`scale\_pos\_weight` théorique (XGBoost) | ≈ 59.0

Le chargement gère l'en-tête GPL (~20 lignes), convertit na en NaN et encode pos→1, neg→0 (src/data/loader.py).

Valeurs manquantes

Le taux moyen de NaN par feature est d'environ — % ; `{{features_with_missing_gt50pct}}` features dépassent 50 % de valeurs manquantes. L'imputation médiane est retenue dans les pipelines de modélisation (robuste aux outliers), appliquée uniquement sur les folds d'entraînement pour éviter toute fuite.

Figure : 01_class_distribution.png

Figure 1.1 — Distribution des classes sur l'ensemble d'entraînement.

Figure : 02_missing_values.png

Figure 1.2 — Analyse des valeurs manquantes.

1.2 Analyse de colinéarité

Corrélation de Spearman

Nous utilisons la corrélation de Spearman (rangs) plutôt que Pearson car :

- les relations capteur–capteur sont souvent **monotones** mais non linéaires ;
- les distributions sont **asymétriques** avec outliers (données industrielles).

La heatmap porte sur les 20 features les plus corrélées entre elles (sélection par paires $|\rho|$ élevées).

Figure : 04_correlation_heatmap.png

Figure 1.3 — Matrice de corrélation de Spearman.

Figure : 05_target_correlation.png

Figure 1.4 — Features les plus corrélées à la cible.

Variance Inflation Factor (VIF)

Pour chaque feature X_j , le VIF mesure l'inflation de variance due à la multicollinéarité :

$$\mathrm{VIF}_j = \frac{1}{1 - R_j^2}$$

où R_j^2 est le R^2 de la régression de X_j sur les autres features.

Interprétation | Seuil retenu

----- | -----

Pas de colinéarité | $\mathrm{VIF} = 1$

Modérée | $1 < \mathrm{VIF} < 5$

Problématique | $\mathrm{VIF} > 5$ (James et al., 2013)

Sévère | $\mathrm{VIF} > 10$

Résultat : — features présentent un $\mathrm{VIF} > 5$. Exemples (top) : voir notebook 01.

Figure : 06_vif_analysis.png

Figure 1.5 — VIF par feature.

Le tableau détaillé est exporté dans `reports/tables/top_10_vif_scores.csv`.

Décision modélisation : ne pas supprimer agressivement avant validation croisée — les modèles L1 (Elastic Net) et arbres gèrent la redondance ; une réduction itérative du VIF reste une piste pour la régression logistique seule.

1.3 Visualisations avancées

Violin plots

Les cinq features les plus corrélées à la cible (Spearman) sont visualisées par classe pour comparer forme, dispersion et séparabilité.

Figure : 07_violin_plots.png

Figure 1.6 — Distributions par classe.

Projection UMAP 2D

UMAP (McInnes et al., 2018) préserve mieux la structure globale que t-SNE, avec un coût calcul raisonnable. Paramètres : `n_neighbors=15`, `min_dist=0.1`, `metric='euclidean'`, `random_state=42`.

Figure : 08_umap_2d.png

Figure 1.7 — Structure des données en 2D.

Lecture : les classes présentent un chevauchement partiel — la séparation n'est pas linéairement parfaite, ce qui justifie des modèles non linéaires (forêts, boosting) en plus d'une baseline Elastic Net.

1.4 Comparaison des stratégies anti-déséquilibre

Protocole : StratifiedKFold(n_splits=5, shuffle=True, random_state=42), pipeline SimpleImputer(median) + StandardScaler + classificateur.

Stratégie | Mécanisme | F1-Macro (CV) | MCC (CV)

----- | ----- | ----- | -----

****A — Algorithme**** | `LogisticRegression(class\_weight='balanced')` | — ± — | — ± —

****B — Données**** | `SMOTE` dans `imblearn.Pipeline` (train fold uniquement) | — ± — | — ± —

Figure : 09_imbalance_comparison.png

Figure 1.8 — F1-Macro et MCC par fold.

Conclusion Chapitre 1

Approche | Avantages | Inconvénients

----- | ----- | -----

****class_weight**** | Rapide, pas de duplication synthétique, pas de sur-apprentissage sur points SMOTE | Peut sous-représenter la frontière de décision

****SMOTE**** | Densifie la région des positifs, peut améliorer le rappel | Coût calcul, risque de bruit si voisinage mal choisi

Choix pour la suite : les modèles linéaires et forêts utilisent `class_weight='balanced'` ; XGBoost exploite `scale_pos_weight ≈ 59` et une variante focal loss (stratégie B, notebook 02). La stratégie retenue pour la régression logistique de comparaison est celle qui maximise le MCC en CV (voir métriques ci-dessus).

Anti-leakage validé : dimensions train/test inchangées ; SMOTE confiné aux folds d'entraînement.

Chapitre 2 — Développement des modèles (Étape 2)

2.1 Modèle 1 — Régression logistique Elastic Net (baseline)

Justification théorique

L'Elastic Net combine pénalités L1 (Lasso) et L2 (Ridge) :

$$\min_{\beta} \left[-\log L(\beta) + \lambda \left(\alpha \|\beta\|_1 + \frac{1-\alpha}{2} \|\beta\|_2^2 \right) \right]$$

- **L1** : sélection / sparsité des capteurs ;
- **L2** : stabilité face à la multicolinéarité (VIF élevés).

C'est une baseline interprétable et rapide.

Hyperparamètres

Paramètre | Grille | Rôle

----- | ----- | -----

`C` | [0.001, 0.01, 0.1, 1, 10] | Inverse de la force de régularisation

`l1\_ratio` | [0, 0.3, 0.5, 0.7, 1] | Part L1 dans la pénalité elastic net

Validation : GridSearchCV, 5 folds stratifiés, scoring='matthews_corrcoef', refit='mcc', solver='saga', class_weight='balanced'.

Résultats (à compléter depuis notebook 02)

Indicateur | Valeur

----- | -----

Meilleur `C` | [ex. 0.1 — voir `grid\_lr.best\_params\_`]

Meilleur `l1\_ratio` | [ex. 0.5]

MCC CV (refit) | [voir sortie GridSearch]

F1-Macro CV | [voir `cv\_summary`]

AUPRC CV | [voir `cv\_summary`]

Temps d'entraînement | [secondes]

2.2 Modèle 2 — Random Forest + proximité OOB

Entraînement

Hyperparamètre | Valeur

----- | -----

`n\_estimators` | 500

```
`max_depth` | `None`  
`min_samples_leaf` | 5  
`class_weight` | `balanced`  
`random_state` | 42
```

Matrice de proximité et outliers

La proximité entre observations i et j est la fréquence où elles partagent la même feuille terminale. Une matrice $60\,000 \times 60\,000$ est irréalisable (~ 28 Go) ; nous sous-échantillons 5 000 points (stratifiés).

- **MDS** sur la dissimilarité $(1 - \text{proximité}) \rightarrow$ visualisation 2D ;
- **Isolation Forest** (`contamination=0.05`) pour repérer les points isolés.

Figure : rf_mds_proximity_outliers.png

Figure 2.1 — Structure de proximité et outliers ($\sim 5\%$).

Interprétation :

- **Nombre d'outliers détectés** : ≈ 250 sur 5 000 (5%).
- Ces points se situent souvent en **zone de frontière** ou présentent des combinaisons de capteurs **atypiques**.
- Le modèle « hésite » lorsque les vecteurs s'éloignent des régions denses apprises — interactions non linéaires et bruit capteur.

Résultats CV / test

Métrique	Valeur
F1-Macro	[CV / test]
AUPRC	[CV / test]
MCC	[CV / test]

2.3 Modèle 3 — XGBoost cost-sensitive + Optuna

Stratégie A — `scale_pos_weight`

Poids relatif des positifs dans les gradients :

$$\text{scale_pos_weight} \approx \frac{n_{\text{neg}}}{n_{\text{pos}}} \approx 59$$

Candidats testés : [10, 30, 59, 77].

Stratégie B — Focal loss personnalisée

$$FL(p_t) = -\alpha_t (1 - p_t)^\gamma \log(p_t), \quad \gamma = 2, \alpha = 0.25$$

Concentre l'apprentissage sur les exemples difficiles (pannes rares mal classées).

Optimisation Optuna (TPE)

Paramètre | Plage | Justification

----- | ----- | -----

`max\_depth` | [3, 8] | Contrôle biais-variance

`learning\_rate` | [0.01, 0.3] log | Pas d'apprentissage

`lambda`, `alpha` | [1e-3, 10] log | Régularisation L2 / L1

`subsample`, `colsample\_bytree` | [0.6, 1.0] | Stochasticité / décorrélation des arbres

`n\_estimators` | [100, 500] | Nombre de boosting rounds

Configuration : TPESampler(seed=42), 50 essais par stratégie (100 au total), objectif = maximiser MCC en CV 5 folds.

Résultats Stratégie A

Indicateur | Valeur

----- | -----

Meilleur `scale\_pos\_weight` | [Optuna]

MCC moyen CV | [study_a.best_value]

Temps | [min]

Figure : optuna_history_strategy_a.png

Figure : optuna_importance_strategy_a.png

Résultats Stratégie B

Indicateur | Valeur

----- | -----

MCC moyen CV | [study_b.best_value]

Temps | [min]

Figure : optuna_history_strategy_b.png

Figure : optuna_importance_strategy_b.png

Comparaison A vs B

Critère | Stratégie A | Stratégie B

----- | ----- | -----

MCC CV | [A] | [B]

Δ MCC | [B - A] |

Simplicité | native XGBoost | Custom objective

Temps | Généralement plus rapide | Souvent plus lent

Choix final : [retenir la stratégie au meilleur MCC CV ; justifier avec les chiffres Optuna et xgboost_best.pkl].

Tableau comparatif des trois modèles

Modèle | F1-Macro | AUPRC | MCC | Temps (s)

----- | ----- | ----- | ---- | -----

Elastic Net | [] | [] | [] | []

Random Forest | [] | [] | [] | []

XGBoost (best) | [] | [] | [] | []

Source recommandée : reports/tables/model_cv_comparison.csv.

Figure : model_cv_comparison.png

Conclusion intermédiaire

Le meilleur modèle global en validation croisée est en principe XGBoost (capacité non linéaire + gestion explicite du déséquilibre). Il sera évalué au chapitre 3 sur le test set (16 000 observations) et analysé par SHAP au chapitre 4.

Chapitre 3 — Évaluation et calibration (Étape 3)

3.1 Métriques avancées sur le test set

Pourquoi exclure l'accuracy ?

Avec $\approx 98,3$ % de négatifs, un classificateur constant « négatif » maximise l'accuracy tout en générant un coût métier catastrophique (FN).

Métriques retenues

F1-Macro — moyenne non pondérée du F1 par classe :

$$F1_c = \frac{2 \cdot P_c \cdot R_c}{P_c + R_c}, \quad F1_{\text{macro}} = \frac{1}{C} \sum_c F1_c$$

AUPRC — aire sous la courbe précision-rappel ; baseline aléatoire $\approx$ proportion de positifs (1.67 %).

MCC — corrélation de Matthews (-1 à $+1$), robuste au déséquilibre :

$$\mathrm{MCC} = \frac{TP \cdot TN - FP \cdot FN}{\sqrt{(TP+FP)(TP+FN)(TN+FP)(TN+FN)}}$$

Coût IDA 2016 :

$$\text{Coût total} = 10 \cdot FP + 500 \cdot FN$$

Résultats test set

Insérer le tableau exporté `reports/tables/final_comparison.csv` :

Modèle | F1-Macro | AUPRC | MCC | Précision | Rappel | Coût IDA (€) | Seuil

----- | ----- | ----- | ---- | ----- | ----- | ----- | -----

Elastic Net | | | | |

Random Forest | | | | |

XGBoost | | | | |

Meilleur modèle (MCC test) : [nom].

3.2 Courbes de performance

Precision–Recall

Figure : pr_curves.png

Meilleure AUPRC : [modèle] = [valeur].

ROC (référence)

Figure : roc_curves.png

Note : en déséquilibre extrême, la ROC peut paraître optimiste ; la PR est prioritaire.

MCC et coût vs seuil

Le seuil 0,5 n'est en général pas optimal. Le notebook 03 balaie les seuils de 0,10 à 0,90 (pas 0,05).

Figure : mcc_threshold.png

- **Seuil optimal MCC :** [thr_mcc] — MCC = [valeur].

Figure : cost_threshold.png

- **Seuil optimal coût :** [thr_cost] — Coût minimal = [€].

Écart MCC / coût : le seuil minimisant le coût pénalise davantage les FN (×500) ; il peut être plus bas que le seuil MCC, augmentant le rappel sur les pannes.

Figure : final_metrics_barplot.png

3.3 Calibration des probabilités

Motivation

Un bon discriminant n'implique pas des probabilités bien calibrées. Or l'atelier prend des décisions sur la base de $P(\text{panne} \mid x)$.

Reliability diagrams & ECE

ECE (Expected Calibration Error) sur 10 bins :

$$\mathrm{ECE} = \sum_{b=1}^B \frac{n_b}{N} \left| \mathrm{acc}(b) - \mathrm{conf}(b) \right|$$

Seuil d'alerte empirique : $\mathrm{ECE} > 0,05 \rightarrow$ recalibration recommandée.

Figure : calibration_before.png

Figure : calibration_comparison.png

Modèle | ECE (avant) | ECE (après) | Méthode

----- | ----- | ----- | -----

XGBoost | [] | [] | Isotonic

Random Forest | [] | [] | Isotonic

Elastic Net | [] | [] | Platt (sigmoid)

Impact : comparer F1-Macro, MCC et coût avant/après CalibratedClassifierCV sur le fold de validation.

Conclusion : [modèle le mieux calibré ; méthode recommandée pour déploiement].

Chapitre 4 — Interprétabilité (Étape 4)

4.1 SHAP (Shapley Additive Explanations)

Fondements

SHAP attribue à chaque feature une contribution ϕ_j vérifiant des axiomes de cohérence (Shapley, 1953 ; Lundberg & Lee, 2017) :

$$f(x) = \phi_0 + \sum_{j=1}^M \phi_j$$

Explainer : shap.TreeExplainer sur le XGBoost retenu.

Échantillon : 5 000 observations du test set (compromis précision / temps).

Importance globale

Figure : shap_summary.png

Top 10 features : voir reports/tables/shap_feature_importance.csv.

Figure : shap_summary_bar.png

Dépendances

Figure : shap_dependence.png

Analyser les effets non linéaires et interactions (couleur = feature d'interaction SHAP).

Explications locales (waterfall)

Figure : shap_waterfall_examples.png

Cas | Question | Piste d'analyse

----- | ----- | -----

****Vrai positif**** | Quels capteurs déclenchent l'alerte ? | Features avec $\phi_j > 0$ élevés

****Faux positif**** | Pourquoi fausse alerte ? | Valeurs atypiques, bruit

****Faux négatif**** | Pourquoi panne ratée ? | ϕ_j contradictoires, signal faible

4.2 Stabilité SHAP sur les folds

Méthodologie : calcul des valeurs SHAP sur plusieurs splits (ou bootstrap) et mesure de l'écart-type par feature.

Catégorie | Features (exemples)

----- | -----

Stables (σ faible) | [liste]

Instables (σ élevé) | [liste]

Les features stables constituent des leviers de surveillance capteur plus fiables en production.

4.3 Interprétation métier

Les capteurs sont anonymisés (aa_000, ab_001, ...) : l'interprétation physique est limitée, mais les patterns restent exploitables :

Facteur de risque | Signal SHAP | Action opérationnelle suggérée

----- | ----- | -----

Feature X élevée | $\phi_X > 0$ | Renforcer la surveillance du capteur associé

Feature Y faible | $\phi_Y < 0$ sur positifs | Contrôle maintenance préventive

Interaction X-W | dépendance non linéaire | Règle composite dans le SCADA

Biais potentiels : corrélations entre capteurs proches physiquement ; dérive temporelle non modélisée (données snapshot).

Recommandations :

1. Surveiller en priorité le top-10 SHAP.
2. Déployer le seuil **coût métier** ([thr_cost]) plutôt que 0,5 par défaut.
3. Déclencher une inspection APS si $P(\text{panne}) > \text{seuil}$ sur deux fenêtres consécutives.

Conclusion générale

Synthèse des résultats

Indicateur | Meilleur modèle / valeur

----- | -----

Modèle retenu | [XGBoost / autre]

MCC (test) | []

AUPRC (test) | []

ECE (après calibration) | []

Coût métier minimal | *[] €*

Seuil opérationnel | []

Réponse à la problématique

- **Déséquilibre** : gestion multi-niveau (`class_weight`, `scale_pos_weight` / focal loss) avec validation par MCC, pas par accuracy.
- **Calibration** : recalibration isotonique / Platt pour aligner probabilités et risque métier.
- **Interprétabilité** : SHAP identifie les capteurs drivers et les cas d'échec (FN critiques).

Limites

1. **Généralisation** — données issues d'un sous-ensemble expert Scania ; dérive possible sur d'autres parcs.
2. **Anonymisation** — pas de lien direct capteur ↔ composant physique APS.
3. **Coûts fixes** — 10 € / 500 € simplifient la réalité atelier (main-d'œuvre, immobilisation).
4. **Test set** — labels de test utilisés pour l'évaluation locale ; en compétition, seul le coût agrégé était retourné.

Perspectives

- **Deep learning** — autoencodeurs pour détection d'anomalies non supervisée en complément.
- **Apprentissage en ligne** — mise à jour du modèle avec flux télématiques.
- **Feature engineering métier** — variables dérivées (gradients pression, écarts à la normale flotte).

Recommandation de déploiement

Paramètre | Recommandation

----- | -----

Modèle | [XGBoost calibré]

Seuil | [thr_cost] (coût) ou compromis MCC/coût validé avec le métier

Ré-entraînement | Mensuel ou après N nouvelles pannes étiquetées

Monitoring | MCC, AUPRC, ECE, coût FP/FN, taux d'alertes

Bibliographie

1. Chen, T., & Guestrin, C. (2016). *XGBoost: A Scalable Tree Boosting System.* KDD.
2. Lundberg, S. M., & Lee, S. I. (2017). *A Unified Approach to Interpreting Model Predictions.* NeurIPS.
3. Chawla, N. V., et al. (2002). *SMOTE: Synthetic Minority Over-sampling Technique.* JAIR.
4. Zadrozny, B., & Elkan, C. (2002). *Transforming Classifier Scores into Accurate Multiclass Probability Estimates.* KDD.
5. McInnes, L., Healy, J., & Melville, J. (2018). *UMAP: Uniform Manifold Approximation and Projection.* arXiv.
6. James, G., et al. (2013). *An Introduction to Statistical Learning.* Springer.
7. UCI Machine Learning Repository. *APS Failure and Operational Data at Scania Trucks* (Dataset 421).
8. Costa, C. F., & Nascimento, M. A. (2016). Résultats challenge IDA — coût $\approx 9\,920$.

Annexes

Annexe A — Code source

- **Dépôt :** [URL GitHub à compléter]
- **Structure :** `notebooks/01–04`, `src/`, `scripts/generate\_all\_notebooks.py`
- **Figures :** `reports/figures/` — voir `reports/CORRESPONDANCE\_FIGURES.md`

Annexe B — Installation et reproduction

(voir repository GitHub pour le code)

Annexe C — Export PDF

(voir repository GitHub pour le code)

Document généré pour le projet « Classification Robuste — APS Scania ». Remplacer les champs [] et {{placeholders}} via scripts/extract_report_metrics.py après exécution complète des notebooks.